📊 CheckIt.AI — Monitoring du pipeline ETL

Qualité des données et performances des exécutions Airflow.

Actualiser les indicateurs

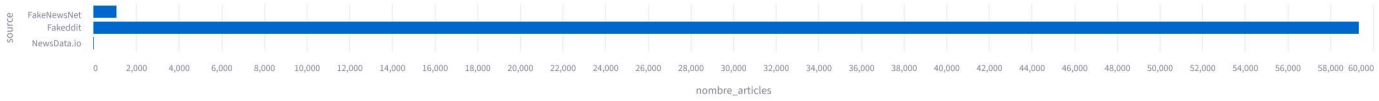
1. Qualité des données

Articles en base	Titres renseignés	Doublons d'identifiant	Articles avec URL d'image
60 428	100.0 %	0.0 %	98.0 %

2. Performance du pipeline Airflow

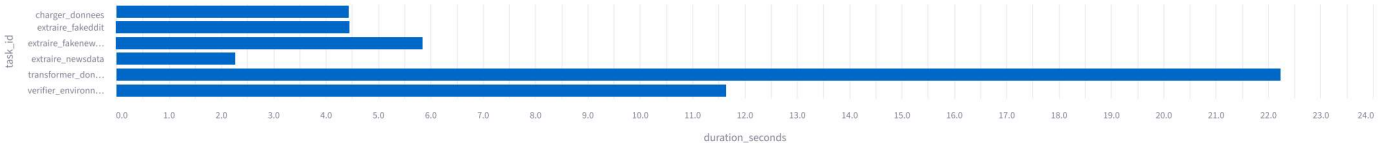
Exécutions	Exécutions réussies	Taux de réussite	Durée moyenne (succès)
5	4	80.0 %	22.3 s

3. Répartition des articles par source



source	nombre_articles
Fakeddit	59342
FakeNewsNet	1056
NewsData.io	30

4. Durée des tâches — dernière exécution réussie



task_id	state	duration_seconds
verifier_environnement	success	11.64
extraire_newsdata	success	2.26
extraire_fakenewsnet	success	5.85
extraire_fakeddit	success	4.45
transformer_donnees	success	22.23
charger_donnees	success	4.43

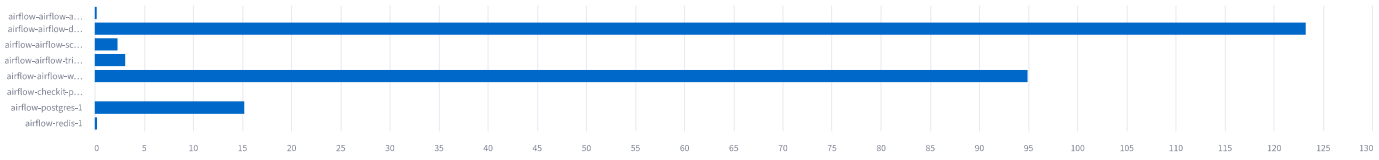
Indicateurs calculés à partir des bases PostgreSQL CheckIt et Airflow. Les URL d'images sont des références, pas une preuve de disponibilité des images.

5. Consommation des ressources Docker

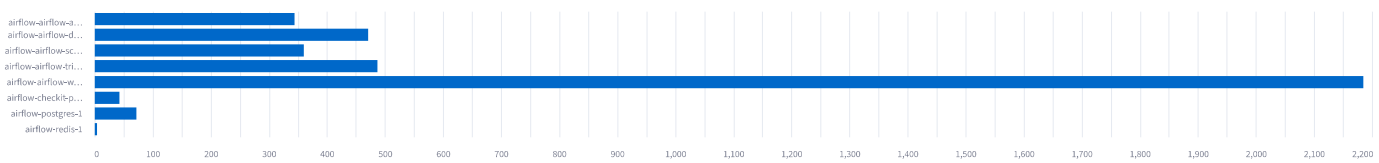
Suivi du coût technique de l'infrastructure : utilisation CPU et mémoire des conteneurs.

Conteneurs actifs	CPU cumulé	Mémoire totale utilisée
8	239.2 %	3,962 MiB

Utilisation du CPU par conteneur



Mémoire utilisée par conteneur



Répartition des ressources par service

service	cpu_pct	memoire_mib
Airflow	223.71	3844.99
PostgreSQL	15.23	113.48
Redis	0.22	3.78

Détail des conteneurs

conteneur	service	cpu_pct	memoire_mib	memoire_pct
airflow-airflow-worker-1	Airflow	94.92	2184.19	13.82
airflow-airflow-triggerer-1	Airflow	3.08	486.7	3.08
airflow-airflow-apiserver-1	Airflow	0.18	343.7	2.17
airflow-airflow-dag-processor-1	Airflow	123.23	470.8	2.98
airflow-airflow-scheduler-1	Airflow	2.3	359.6	2.27
airflow-postgres-1	PostgreSQL	15.23	71.38	0.45
airflow-checkit-postgres-1	PostgreSQL	0	42.1	0.27
airflow-redis-1	Redis	0.22	3.78	0.02

Méthodologie : mesures instantanées obtenues avec 'docker stats --no-stream'. Le CPU peut dépasser 100 % sur plusieurs cœurs. Les valeurs représentent l'infrastructure active, et non le coût total d'une exécution ETL. Les pourcentages CPU cumulés ne représentent pas un taux global d'utilisation.